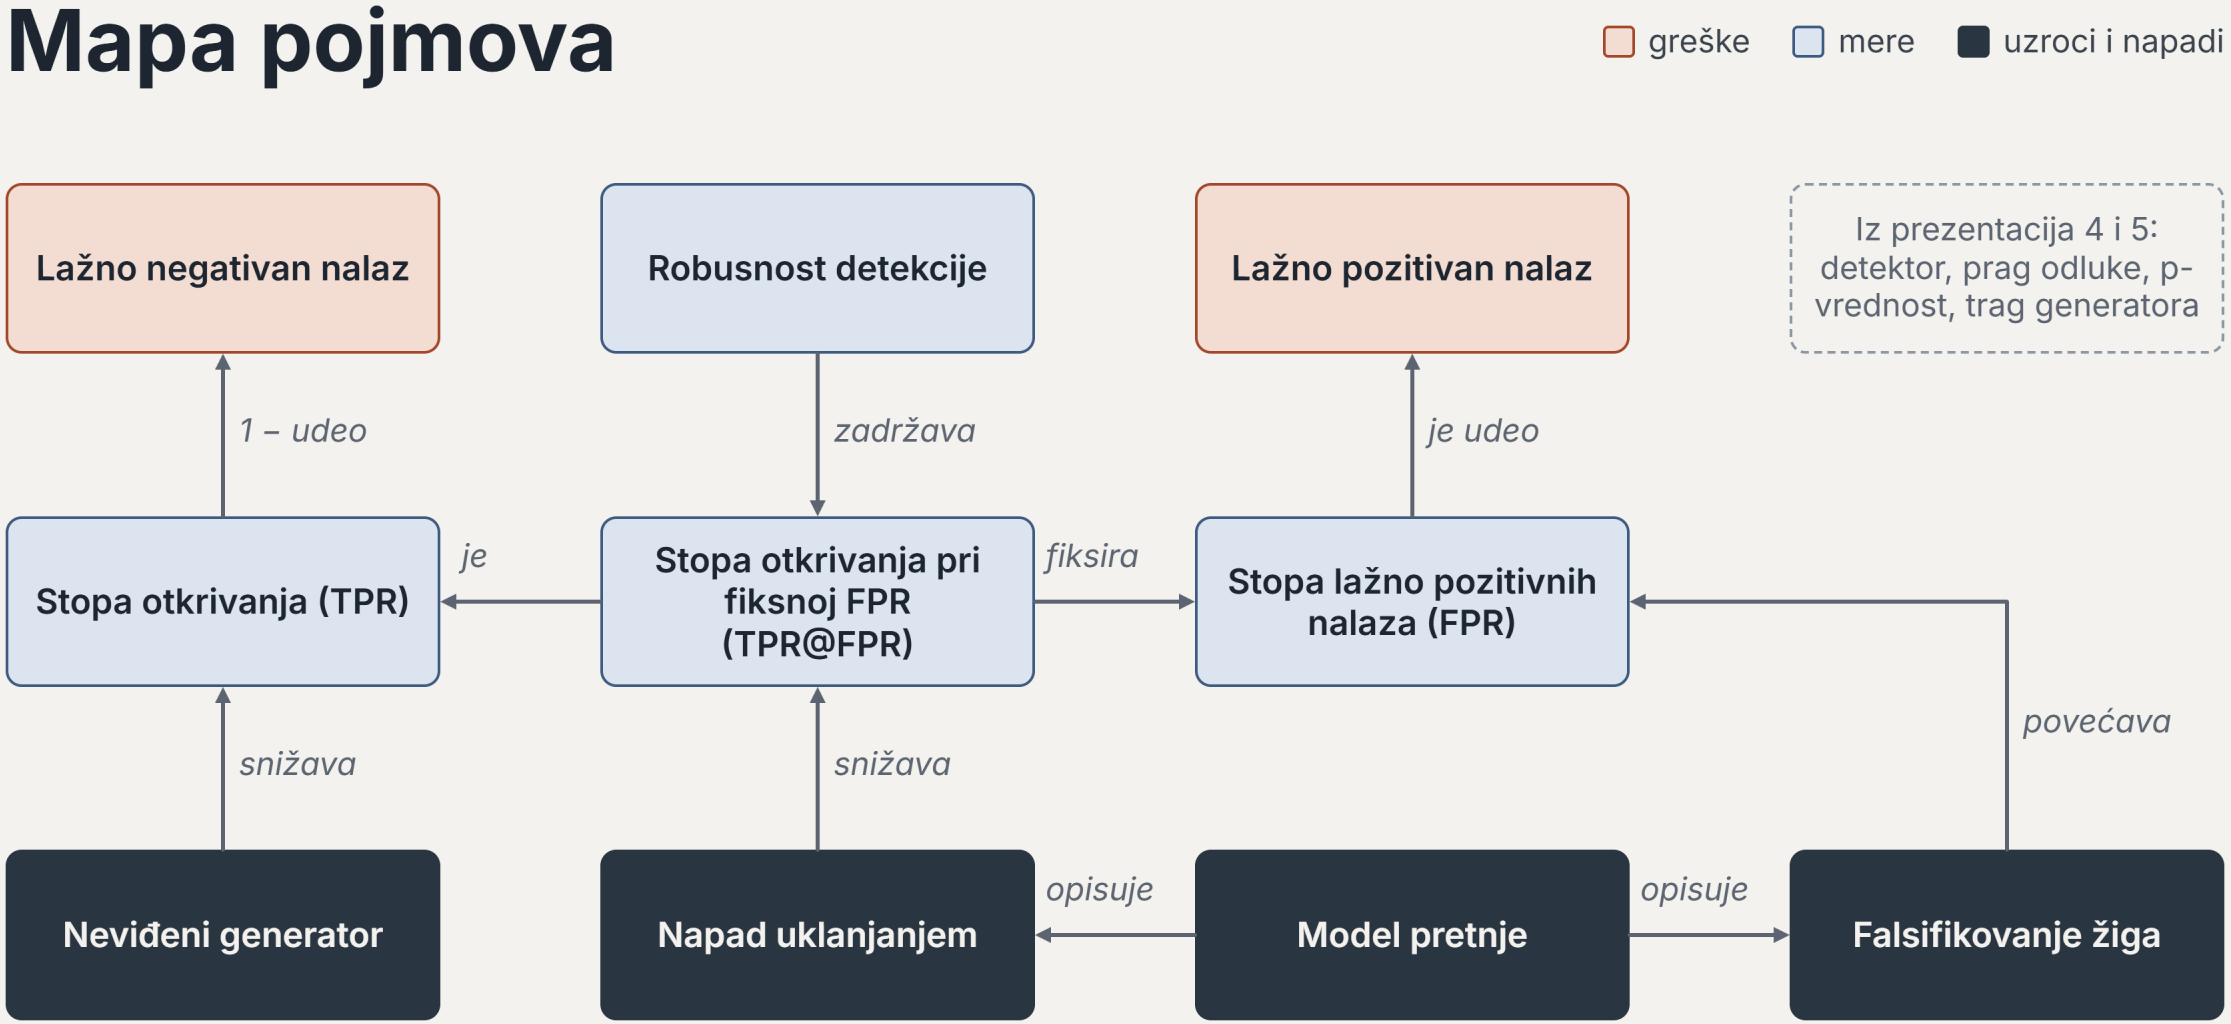
BAZA ZNANJA · DETEKCIJA AI GENERISANOG SADRŽAJA

Greške i napadi na detekciju

Kako se meri pouzdanost detektora i kako ga napadač zaobilazi

Mapa pojmova



Isprekidan okvir: pojmovi iz prezentacija 4 i 5

KONTEKSTI PRIMERA

Kocka i agencija Vidik

KOCKA

Pravilo provere: kocka je nameštena ako u 10 bacanja padne bar k šestica; podrazumevano k = 4.

- **Crvena kocka**: poštena, šestica 1/6
- **Plava kocka**: nameštena, šestica 1/2
- **Zelena kocka** (nova): nameštena na jedinicu
- **Varalica** (nova): prepravlja zapisnik

AGENCIJA VIDIK

- **Detektor koji agencija koristi**: ocenjuje primljeni materijal i poredi ocenu sa pragom
- **Nalog „očevidac“**: šalje generisan opis događaja i fotografiju poplave
- **Dopisnici**: šalju autentične, često noćne i mutne snimke
- **Arhiva primljenih fotografija**: ljudski sadržaj na kome se meri lažna optužba

Novi elementi konteksta Kocka upisani su u konteksti/Kocka.md

POJAM 1 / 10 · GREŠKE DETEKTORA

Lažno pozitivan nalaz *(false positive)*

DEFINICIJA

Odluka detektora da je primerak generisan, doneta za primerak koji nije generisan. Nastaje kada ocena ljudskog primerka pređe prag odluke.

KOCKA

Crvena, poštena kocka u 10 bacanja slučajno da 5 šestica. Pravilo „bar 4 šestice“ je proglasi nameštenom.

Kontraprimer: plava, nameštena kocka proglašena nameštenom. To je tačan nalaz.

AGENCIJA VIDIK

Dopisnik pošalje noćnu, mutnu fotografiju nesreće. Detektor joj da ocenu iznad praga: redakcija odbije autentičan snimak i posumnja u dopisnika.

Kontraprimer: fotografija poplave naloga „očevidac“ označena kao generisana. Ona jeste generisana.

Izvor: T. Fawcett, „An introduction to ROC analysis“, Pattern Recognition Letters, 2006

Lažno negativan nalaz *(false negative)*

DEFINICIJA

Odluka detektora da primerak nije generisan, doneta za primerak koji jeste generisan. Nastaje kada ocena generisanog primerka ostane ispod praga odluke.

KOCKA

Plava kocka je nameštena, ali u 10 bacanja padnu samo 3 šestice. Pravilo je proglasi poštenom.

Kontraprimer: crvena, poštena kocka proglašena poštenom. To je tačan nalaz.

AGENCIJA VIDIK

Opis događaja naloga „očevidac“ napisao je jezički model. Detektor mu da ocenu ispod praga, pa ga redakcija objavi kao svedočenje očevica.

Kontraprimer: izveštaj dopisnika koji detektor označi kao ljudski. On jeste ljudski.

Izvor: T. Fawcett, „An introduction to ROC analysis“, Pattern Recognition Letters, 2006

POJAM 3 / 10 · MERE POUZDANOSTI

Stopa lažno pozitivnih nalaza *(FPR)*

DEFINICIJA

Udeo lažno pozitivnih nalaza među svim primercima koji nisu generisani, za dati detektor i prag odluke.

FPR = FP / (FP + TN)

KOCKA

≈ 7%

provera crvene, poštene kocke pravilo „bar 4 šestice“ proglasi nameštenom.

AGENCIJA VIDIK

3%

30 od 1000 sigurno ljudskih fotografija iz arhive detektor označi kao generisane.

Kontraprimer: 30 grešaka među 50 označenih (60%) nije FPR. Računa se među označenima, ne među ljudskim.

Izvor: T. Fawcett, „An introduction to ROC analysis“, Pattern Recognition Letters, 2006

POJAM 4 / 10 · MERE POUZDANOSTI

Stopa otkrivanja *(true positive rate, TPR)*

DEFINICIJA

Udeo generisanih primeraka koje detektor označi kao generisane, za dati prag odluke; jednaka je 1 – udeo lažno negativnih nalaza.

TPR = TP / (TP + FN)

KOCKA

≈ 83%

provera plave, nameštene kocke pravilo „bar 4 šestice“ proglasi nameštenom.

AGENCIJA VIDIK

90%

450 od 500 fotografija iz modela slika iz teksta detektor označi kao generisane.

Kontraprimer: tačnost nije TPR. Ako je 1% fotografija generisano, detektor koji sve proglasi ljudskim ima tačnost 99%, a TPR 0%.

Izvor: T. Fawcett, „An introduction to ROC analysis“, Pattern Recognition Letters, 2006

POJAM 5 / 10 · MERE POUZDANOSTI

Stopa otkrivanja pri fiksnoj FPR *(TPR@FPR)*

DEFINICIJA

Stopa otkrivanja koju detektor postiže kada je prag odluke izabran tako da stopa lažno pozitivnih nalaza ne bude veća od zadate vrednosti, npr. 1%.

KOCKA · PRAVILO „BAR K ŠESTICA“

Prag k	FPR (crvena)	TPR (plava)
3	23%	95%
4	7%	83%
5	1,5%	62%

Dozvoljeno najviše 5% lažno pozitivnih: prag 5, TPR@FPR = 62%, a ne 95%.

AGENCIJA VIDIK · DVA DETEKTORA

Detektor	Podrazumevani prag	Pri FPR 1%
A	92% (FPR 10%)	40%
B	85% (FPR 2%)	80%

Agencija sme da optuži najviše 1% autentičnih snimaka: bolji je B.

Izvor: K. Krishna i dr., „Paraphrasing evades detectors of AI-generated text...“, NeurIPS 2023

Neviđeni generator *(unseen generator)*

DEFINICIJA

U odnosu na dati naučeni detektor, generativni model čiji primerci nisu bili u trening skupu tog detektora, pa njegovi tragovi detektoru mogu biti nepoznati.

KOCKA

Pravilo „bar 4 šestice“ izvedeno je na plavoj kocki. Zelena kocka je nameštena na jedinicu: šestica joj pada ređe nego poštenoj, pa je pravilo proglasi nameštenom u oko 1% provera.

AGENCIJA VIDIK

Detektor fotografija treniran je na licima iz modela lica (GAN). Fotografiju poplave napravio je model slika iz teksta, sa drugačijim tragovima: detektor je označi kao ljudsku.

Kontraprimer: nova profilna fotografija iz modela lica. Detektor je video taj generator.

Izvor: U. Ojha, Y. Li, Y. J. Lee, „Towards Universal Fake Image Detectors...“, CVPR 2023

Model pretnje *(threat model)*

DEFINICIJA

Eksplicitan opis napadača u odnosu na koga se procenjuje sistem detekcije: šta mu je cilj, šta zna o detektoru i šta može da uradi sa sadržajem i detektorom.

KOCKA · DVA MODELA

1. Varalica ne zna pravilo i ne dira zapisnik.

2. Varalica zna pravilo „bar 4 šestice“ i sme da prepravi poneki broj u zapisniku.

Ista provera je pouzdana u prvom modelu, a beskorisna u drugom.

AGENCIJA VIDIK · NALOG „OČEVIDAC“

Cilj: da redakcija objavi generisanu fotografiju poplave.

Znanje: ne zna koji detektor agencija koristi ni ključ žiga.

Mogućnosti: kompresuje, iseca, šalje sa više naloga.

Kontraprimer: spisak modela kojima se nalog služi. On opisuje generisanje, a ne napadača.

Izvor: A. Vassilev i dr., NIST AI 100-2e2025, odeljci 2.1.2–2.1.4

Napad uklanjanjem *(removal attack)*

DEFINICIJA

Namerna izmena generisanog primerka koja zadržava njegov smisao, a uklanja ili slabi žig ili trag generatora, tako da ga detektor više ne označi kao generisan.

KOCKA

83% → 22%

Varalica u zapisniku plave kocke prepravi svaku drugu šesticu. Toliko pada otkrivanje pravilom „bar 4 šestice“.

AGENCIJA VIDIK

Nalog „očevidac“ parafrazira opis drugim jezičkim modelom, a fotografiju poplave smanji, iseče i ponovo kompresuje. Detektor oba primerka označi kao ljudska.

Kontraprimer: redakcija sama kompresuje fotografiju za portal. Tragovi slabe, ali to nije napad.

Izvor: K. Krishna i dr., NeurIPS 2023; N. Jovanović i dr., „Watermark Stealing in LLMs“, ICML 2024

Falsifikovanje žiga *(watermark forgery)*

DEFINICIJA

Napad u kome napadač pravi primerak koji nije generisao model sa datim ključem žiga, a koji detekcija sa žigom ipak proglasi primerkom sa tim žigom.

JEDNOSTAVAN PRIMER · NOVČANICA

Falsifikator nauči da oponaša skriveni znak koji se vidi pod posebnim svetlom i odštampa ga na svom papiru. Provera svetlom proglasi novčanicu pravom.

AGENCIJA VIDIK

Napadač iz odgovora jezičkog modela proceni zelene liste, napiše izveštaj sa mnogo zelenih tokena i pošalje ga u ime dopisnika. Provera žiga ga proglasi generisanim.

Kontraprimer: ljudski izveštaj koji slučajno ima mnogo zelenih tokena. To je lažno pozitivan nalaz.

Izvor: N. Jovanović, R. Staab, M. Vechev, „Watermark Stealing in Large Language Models“, ICML 2024

POJAM 10 / 10 · MERE POUZDANOSTI

Robusnost detekcije *(detection robustness)*

DEFINICIJA

Svojstvo detektora da zadrži stopu otkrivanja pri fiksnoj FPR kada su generisani primerci izmenjeni, slučajno ili napadom uklanjanjem. Meri se padom te stope posle izmene.

KOCKA · PRAVILO „BAR 5 ŠESTICA“, FPR 1,5%

62% → 8%

Pad otkrivanja plave kocke kada varalica prepravi svaku drugu šesticu: pravilo nije robusno.

AGENCIJA VIDIK · FPR 1%

90%	85%	20%
bez izmene	posle kompresije	posle napada

Kontraprimer: detektor koji sve kompresovane fotografije proglasi generisanim. TPR ostaje, ali raste FPR.

Izvor: J. Kirchenbauer i dr., ICLR 2024; M. Saberi i dr., ICLR 2024